МИНОБРНАУКИ РОССИИ САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ «ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА) Кафедра МО ЭВМ

ОТЧЕТ

по лабораторной работе №5

по дисциплине «Построение и анализ алгоритмов»

Тема: Поиск набора подстрок в строке (Ахо-Корасик)
Вариант: 2

Студентка гр. 3388	Титкова С.Д.
Преподаватель	Жангиров Т.Р

Санкт-Петербург 2025

Цель работы:

Изучить принцип работы алгоритма Ахо-Корасик для нахождения подстрок в строке. Решить с его помощью задачи.

Задание 1:

Разработайте программу, решающую задачу точного поиска набора образцов.

Вход:

Первая строка содержит текст $(T,1 \le |T| \le 100000T)$.

Вторая - число n (1 \leq n \leq 3000), каждая следующая из n строк содержит шаблон из набора P={p 1,...,p n} 1 \leq |p i| \leq 75.

Все строки содержат символы из алфавита {A,C,G,T,N}.

Выход:

Все вхождения образцов из P в T.

Каждое вхождение образца в текст представить в виде двух чисел - i p Где i - позиция в тексте (нумерация начинается с 1), с которой начинается вхождение образца с номером p (нумерация образцов начинается с 1).

Строки выхода должны быть отсортированы по возрастанию, сначала номера позиции, затем номера шаблона.

Sample Input:

NTAG

3

TAGT

TAG

Т

Sample Output:

22

23

Задание 2:

Используя реализацию точного множественного поиска, решите задачу образца точного поиска ДЛЯ одного с джокером. В шаблоне встречается специальный символ, именуемый джокером (wild card), который "совпадает" с любым символом. По заданному содержащему шаблоны образцу P необходимо найти все вхождения Р в текст Т. джокером? встречается дважды Например, образец ab??c?ab??c? с тексте харуссвававсах.

Символ джокер не входит в алфавит, символы которого используются в T. Каждый джокер соответствует одному символу, а не подстроке неопределённой длины. В шаблон входит хотя бы один символ не джокер, т.е. шаблоны вида ??? недопустимы. Все строки содержат символы из алфавита $\{A,C,G,T,N\}$.

Вход:

Текст $(T,1 \le |T| \le 100000)$

Шаблон (P,1≤|P|≤40)

Символ джокера

Выход:

Строки с номерами позиций вхождений шаблона (каждая строка содержит только один номер).

Номера должны выводиться в порядке возрастания.

Sample Input:

ACTANCA

A\$\$A\$

\$

Sample Output:

1

Реализация

Описание алгоритма Ахо-Корасика для точного поиска образцов:

Алгоритм Ахо-Корасика предназначен для эффективного поиска всех вхождений множества заданных шаблонов P={p_1,p_2,...,p_n} в текст Т. Он использует структуру данных, называемую бором (trie), дополненную суффиксными и конечными ссылками, что позволяет выполнять поиск за один проход по тексту независимо от числа шаблонов. В данной реализации алгоритм также подсчитывает количество вершин в автомате и определяет шаблоны, имеющие пересечения с другими вхождениями в тексте.

Шаги алгоритма

Создаётся корневое состояние (0) с fail = 0 (суффиксная ссылка) и outputlink = -1 (конечная ссылка). Определяется максимальное число состояний как сумма длин всех шаблонов плюс корень ($\sum |pi|+1$).

Для каждого шаблона р_i из Р. Начиная с корня, для каждого символа с в р_i добавляется новое состояние, если перехода по с ещё нет. Счётчик вершин state_count увеличивается на 1 для каждого нового состояния. Конечное состояние шаблона отмечается его индексом i в массиве output.

Далее строится автомат. Используется очередь для обхода состояний в порядке ширины (BFS). Для каждого состояния из корня: fail = 0, output_link устанавливается как само состояние, если оно содержит шаблон, иначе -1.

Для остальных состояний. Суффиксная ссылка fail[next_state] определяется поиском самого длинного суффикса текущей строки, доступного через fail[current_state]. Конечная ссылка output_link[next_state] указывает на ближайший узел с шаблоном по цепочке fail, либо на -1.

Затем производится поиск в тексте. Проход по символам текста Т с использованием текущего состояния current_state. Если перехода по символу нет, алгоритм следует по fail до корня или подходящего состояния. При достижении состояния с непустым output или через output_link фиксируются все вхождения шаблонов с вычислением их позиций.

Также по заданию из варианта требовалось осуществить: подсчёт вершин: возвращается state_count. Определение пересечений: для каждого вхождения вычисляются начало и конец, проверяются пересечения между парами вхождений.

.

Описание функций и структур:

Был создан класс AhoCorasick в нём определены следующие поля:

- Patterns используется для построения бора и вычисления позиций вхождений.
- *Transitions* представляет бор, обеспечивая быстрый доступ к следующему состоянию
- *Output* хранит информацию о завершении шаблонов в вершинах бора
- Fail суффиксные ссылки для быстрого перехода при несовпадении символов
- Output_link конечные ссылки для эффективного извлечения всех совпадени
- *State_count* используется для подсчёта вершин и ограничения массивов. Также были реализованы методы класса:
- __init__(self, patterns) метод, который инициализирует автомат Ахо-Корасика для заданного набора шаблонов.
- *Build_automaton(self)* метод, который строит бор и автомат Ахо-Корасика с суффиксными и конечными ссылками.
- Search(self, text) метод, который ищет все вхождения шаблонов в тексте
- *Get_vertex_count(self)* метод, который возвращает количество вершин в автомате
- Find_overlapping_patterns(self, text, results) метод, который определяет шаблоны, вхождения которых пересекаются с другими.

Также была написана функция *process_search(T, patterns)*, которая обрабатывает поиск шаблонов в тексте и возвращает результаты.

Оценка сложности алгоритма:

Временная сложность

Построение бора:

 Для каждого символа всех шаблонов создаётся или используется состояние: О(∑|pi|), где| ∑|pi| — суммарная длина шаблонов

Построение автомата:

- Обход BFS по всем состояниям (до ∑|pi|+1) с проверкой переходов для каждого символа алфавита.
- \circ $O(\sum |pi|)$ для небольшого алфавита, так как $|\Sigma|$ считается константой.

Поиск:

- Проход по тексту: O(|T|) переходов, каждый с O(1) по fail и output_link благодаря конечным ссылкам.
- о Извлечение совпадений: O(z), где z число вхождений.

$\underline{\textit{Umoe:}} O(|T|+z)$

Пространственная сложность

Бор:

- \circ transitions: $O(\sum |pi|)$ состояний, каждый с $O(|\Sigma|)$ переходов (в худшем случае).
- \circ output: $O(\sum |pi|)$ для хранения индексов шаблонов.

Ссылки:

 \circ fail, output_link: $O(\sum |pi|)$ элементов.

Результаты:

- о results: O(z) пар.
- o overlap_patterns: O(n) в худшем случае, где n число шаблонов.

 $\underline{\mathit{Итог:}}\ O(\sum |pi|)$ для автомата плюс O(z) для результатов, итого $O(\sum |pi|+z)$.

Тестирование

Таблица 1. Тестирование.

Входные данные	Выходные данные
ACGT	
2	
ACGTACGT	
CGTA	
AAAAA	11
2	1 2
A	2 1
AA	2 2
	3 1
	3 2
	4 1
	4 2
	5 1
ACGTACGT	11
3	2 2
AC	3 3
CG	5 1
GT	6 2
	7 3
ACGTACGT	11
3	1 2
A	1 3
AC	5 1
ACG	5 2
	5 3

Описание Алгоритма Ахо-Корасика с джокерами:

Алгоритм Ахо-Корасика в данной реализации адаптирован для поиска всех вхождений шаблона Р с джокерами (специальный символ, обозначающий совпадение с любым символом) в тексте Т. Он использует бор (trie) с суффиксными и конечными ссылками для поиска всех безджокерных подстрок шаблона Р, а затем проверяет полное соответствие Р в найденных позициях с учётом джокеров. Алгоритм также подсчитывает количество вершин в автомате и определяет шаблоны с пересекающимися вхождениями.

Шаги алгоритма

Создаётся корневое состояние (0) с fail = 0 (суффиксная ссылка) и outputlink = -1 (конечная ссылка). Определяется максимальное число состояний как сумма длин всех шаблонов плюс корень ($\sum |pi|+1$).

Для каждой подстроки Q_i из P. Начиная с корня, создаются состояния для каждого символа с, если перехода нет. Счётчик state_count увеличивается для новых состояний. Конечное состояние подстроки помечается её индексом в output.

Далее производится построение автомата. Для этого будет использоваться обход в ширину (BFS). Для детей корня: fail = 0, output_link— само состояние, если оно конец шаблона, иначе -1. Для остальных: fail определяется поиском через fail родителя, output_link— ближайший узел с шаблоном.

Далее проходим по T с использованием transitions и fail для переходов. Совпадения извлекаются через output и output_link.

Для каждого совпадения Q_i на позиции j: $C[j-l_i] += 1$, где l_i — стартовая позиция Q_i в P. Позиции i, где C[i] = k и T[i:i+|P|] соответствует P с джокерами, добавляются в результат.

Также по заданию из варианта требовалось осуществить: подсчёт вершин: возвращается state_count. Определение пересечений: для каждого вхождения вычисляются начало и конец, проверяются пересечения между парами вхождений

Описание функций и структур:

Был создан класс AhoCorasick в нём определены следующие поля:

- Patterns используется для построения бора и вычисления позиций вхождений.
- *Transitions* представляет бор для поиска подстрок.
- Output хранит совпадения подстрок
- Fail суффиксные ссылки для быстрого перехода при несовпадении символов
- Output_link конечные ссылки для эффективного извлечения всех совпадени
- *State_count* используется для подсчёта вершин и ограничения массивов. Также были реализованы методы класса:
- __init__(self, patterns) метод, который инициализирует автомат Ахо-Корасика для заданного набора шаблонов.
- *Build_automaton(self)* метод, который строит бор и автомат Ахо-Корасика с суффиксными и конечными ссылками.
- Search(self, text) метод, который ищет все вхождения шаблонов в тексте
- *Get_vertex_count(self)* метод, который возвращает количество вершин в автомате
- Find_overlapping_patterns(self, text, results) метод, который определяет шаблоны с пересечениями

Также была написана функция *find_pattern_with_wildcards(T, P, wildcard)*, которая находит вхождения Р с джокерами в Т.

Оценка сложности алгоритма:

Временная сложность:

Разбиение Р:

о O(|P|) для разбиения по wildcard и вычисления start positions.

Построение бора:

 \circ O(\sum |Qi|) для добавления подстрок, где \sum |Qi| \leq |P|.

Построение автомата:

 \circ O(Σ |Qi|) для BFS с фиксированным алфавитом ($|\Sigma|$ — константа).

Поиск:

 \circ O(|T|) для прохода по тексту, O(z) для извлечения совпадений (z — число вхождений).

Проверка джокеров:

 \circ O(|T|·|P|) для анализа С и проверки символов Р в каждой позиции.

Пересечения:

 \circ O(z^2) для сравнения всех пар вхождений.

<u>Итого:</u> $O(\sum |Qi|+|T|\cdot|P|+z2)$

Пространственная сложность

Бор:

- transitions: O(∑|Qi|) состояний.
- o output, fail, ooutput_link: $O(\sum |Qi|)$.

Поиск:

- o C: O(|T|).
- \circ results: O(z) O(z) O(z).
- \circ overlap_patterns: O(k), где k≤|P|.

Общая: $O(\sum |Qi|+|T|+z)$, z≤|T|.

Тестирование

Таблица 2. Тестирование.

Входные данные	Выходные данные
AAAAA	1
A*A	2
*	3
ACGTACGT	1
CG	5
*	
ACTANCA	1
A\$\$A\$	
\$	
NTAG	2
T*G	
*	

Вывод

В ходе лабораторной работы были написаны программы с использованием алгоритма Ахо-Корасика. Также дополнительно было сделано: подсчёт вершин и определение пересечений.

Исходный код программы см. в ПРИЛОЖЕНИИ А.

ПРИЛОЖЕНИЕ А.

ИСХОДНЫЙ КОД ПРОГРАММЫ

aho_1.py

```
from collections import deque
DEBUG = False
class AhoCorasick:
    def init (self, patterns):
        self.patterns = [p for p in patterns if p]
        self.num patterns = len(self.patterns)
        self.max states = sum(len(p) for p in self.patterns) + 1
        self.transitions = [{} for _ in range(self.max_states)]
        self.output = [[] for in range(self.max states)]
        self.fail = [0] * self.max states
        self.output_link = [-1] * self.max_states
        self.state count = 0
        self.build automaton()
    def build automaton(self):
        root = 0
        self.fail[root] = root
        self.output link[root] = -1
        self.state count = 1
        if DEBUG:
            print("Построение бора:")
        for i in range (self.num patterns):
            current state = root
            for char in self.patterns[i]:
                if char not in self.transitions[current state]:
                    self.transitions[current state][char] =
self.state count
                    if DEBUG:
                        print(f"Добавлено ребро из состояния
{current state} в состояние {self.state count} по символу '{char}'")
                    self.state count += 1
                current state = self.transitions[current state][char]
            self.output[current state].append(i)
            if DEBUG:
                print(f"Добавлен шаблон {i} в состояние
{current state}")
        if DEBUG:
            print("\nПостроение автомата:")
        queue = deque()
        for char in self.transitions[root]:
            state = self.transitions[root][char]
            self.fail[state] = root
            self.output_link[state] = state if self.output[state] else
-1
            queue.append(state)
            if DEBUG:
                print(f"Установлен fail-переход для состояния {state}
в состояние {root}")
```

```
while queue:
            current state = queue.popleft()
            for char in self.transitions[current state]:
                next_state = self.transitions[current_state][char]
                queue.append(next state)
                fail state = self.fail[current state]
                while fail state != root and char not in
self.transitions[fail state]:
                    fail state = self.fail[fail state]
                self.fail[next state] =
self.transitions[fail state].get(char, root)
                if DEBUG:
                    print(f"Установлен fail-переход для состояния
{next state} в состояние {self.fail[next state]}")
                fail = self.fail[next state]
                self.output_link[next_state] = fail if
self.output[fail] else self.output link[fail]
                if DEBUG:
                    print(f"Установлен output-переход для состояния
{next state} в состояние {self.output link[next state]}")
        if DEBUG:
            print("\nПостроенный автомат:")
            for state in range(self.state count):
                print(f"Состояние {state}:")
                print(f" Переходы: {self.transitions[state]}")
                print(f" Выходы: {self.output[state]}")
                print(f" Fail-переход: {self.fail[state]}")
                print(f" Output-переход: {self.output link[state]}")
    def search(self, text):
        current state = 0
        results = []
        if DEBUG:
            print("\nПроцесс поиска:")
        for i in range(len(text)):
            char = text[i]
            while current state != 0 and char not in
self.transitions[current state]:
                current state = self.fail[current state]
                if DEBUG:
                    print(f"Переход по fail-ссылке в состояние
{current state}")
            if char in self.transitions[current state]:
                current state = self.transitions[current_state][char]
                if DEBUG:
                    print(f"Переход в состояние {current state} по
символу '{char}'")
            else:
                current state = 0
                if DEBUG:
                    print(f"Символ '{char}' не найден, переход в
корневое состояние")
```

```
temp state = current state
            visited = set()
            while temp state != -1 and temp state not in visited:
                visited.add(temp state)
                if self.output[temp_state]:
                    for pattern index in self.output[temp state]:
                        pos = i - len(self.patterns[pattern index]) +
2
                        results.append((pos, pattern index + 1))
                        if DEBUG:
                            print(f"Найден шаблон {pattern index + 1}
на позиции {pos}")
                temp state = self.output link[temp state]
        return sorted(results)
    def get vertex count(self):
        return self.state count
    def find overlapping patterns(self, text, results):
        if not results:
            return set()
        occurrences = [(pos, pos + len(self.patterns[pattern num - 1])
- 1, pattern num)
                       for pos, pattern num in results]
        overlap patterns = set()
        for i in range(len(occurrences)):
            start1, end1, pattern1 = occurrences[i]
            for j in range(len(occurrences)):
                if i != j:
                    start2, end2, pattern2 = occurrences[j]
                    if start1 <= end2 and start2 <= end1:</pre>
                        overlap patterns.add(pattern1)
                        overlap patterns.add(pattern2)
        return overlap patterns
def process search(T, patterns):
    automaton = AhoCorasick(patterns)
    results = automaton.search(T)
    vertex_count = automaton.get_vertex_count()
    overlapping = automaton.find overlapping patterns(T, results)
    return results, vertex count, overlapping
if __name__ == "__main ":
    T = input().strip()
    n = int(input())
    patterns = [input().strip() for _ in range(n)]
    results, vertex count, overlapping = process search(T, patterns)
    print(f"\nКоличество вершин в автомате: {vertex count}")
    for pos, pattern num in results:
        print(pos, pattern num)
    if overlapping:
        print("Шаблоны с пересечениями:", ", ".join(str(p) for p in
sorted(overlapping)))
```

```
else:
        print ("Шаблоны с пересечениями отсутствуют")
aho mask.py
from collections import deque
DEBUG = False
class AhoCorasick:
    def init (self, patterns):
        self.patterns = [p for p in patterns if p]
        self.num patterns = len(self.patterns)
        self.max states = sum(len(p) for p in self.patterns) + 1
        self.transitions = [{} for _ in range(self.max_states)]
self.output = [[] for _ in range(self.max_states)]
        self.fail = [0] * self.max_states
        self.output link = [-1] * self.max states
        self.state count = 0
        self.build automaton()
    def build automaton(self):
        root = 0
        self.fail[root] = root
        self.output_link[root] = -1
        self.state count = 1
        if DEBUG:
            print("Построение бора:")
            print(f"Создано состояние {root} (корень)")
        for i in range (self.num patterns):
             if DEBUG:
                 print(f"\nДобавление шаблона \{i + 1\}:
'{self.patterns[i]}'")
            current state = root
             for char in self.patterns[i]:
                 if char not in self.transitions[current state]:
                     new state = self.state count
                     self.transitions[current state][char] = new state
                     if DEBUG:
                         print(f"Создано состояние {new state} с
переходом из {current_state} по '{char}'")
                     self.state count += 1
                 else:
                     new state = self.transitions[current state][char]
                     if DEBUG:
                         print(f"Переход из {current state} по '{char}'
в существующее состояние {new state}")
                current state = new state
            self.output[current state].append(i)
             if DEBUG:
                 print(f"Состояние {current state} отмечено как конец
шаблона {i + 1}")
        if DEBUG:
            print("\nПостроение суффиксных и конечных ссылок:")
        queue = deque()
        for char in self.transitions[root]:
```

```
state = self.transitions[root][char]
            self.fail[state] = root
            self.output link[state] = state if self.output[state] else
-1
            if DEBUG:
                print(f"Cостояние {state}: fail = {root}, output link
= {self.output link[state]}")
            queue.append(state)
        while queue:
            current state = queue.popleft()
            for char in self.transitions[current state]:
                next state = self.transitions[current state][char]
                queue.append(next state)
                if DEBUG:
                    print(f"\nОбрабатываем переход из {current state}
по '{char}' в {next state}")
                fail state = self.fail[current state]
                while fail state != root and char not in
self.transitions[fail state]:
                    if DEBUG:
                        print(f"Состояние {fail state} не имеет
перехода по '{char}', переходим к fail = {self.fail[fail state]}")
                    fail state = self.fail[fail state]
                self.fail[next state] =
self.transitions[fail_state].get(char, root)
                if DEBUG:
                    print(f"Установлена суффиксная ссылка:
fail[{next state}] = {self.fail[next state]}")
                fail = self.fail[next state]
                self.output link[next state] = fail if
self.output[fail] else self.output link[fail]
                if DEBUG:
                    print(f"Установлена конечная ссылка:
output link[{next state}] = {self.output link[next state]}")
        if DEBUG:
            print("\nПостроенный автомат:")
        for state in range(self.state count):
            trans = "{" + ", ".join(f"'{k}': {v}" for k, v in
self.transitions[state].items()) + "}"
            if DEBUG:
                print(f"Cостояние {state}: transitions = {trans}, fail
= {self.fail[state]}, "
                      f"output = {self.output[state]}, output link =
{self.output link[state]}")
    def search(self, text):
            print("\nПроцесс поиска в тексте:", text)
        current state = 0
        results = []
        for i in range(len(text)):
            char = text[i]
            if DEBUG:
```

```
print(f"\nПозиция \{i + 1\}: символ '\{char\}', текущее
cocтoяние = {current state}")
            while current state != 0 and char not in
self.transitions[current state]:
                if DEBUG:
                    print(f"Heт перехода по '{char}' из
{current state}, переходим к fail = {self.fail[current state]}")
                current state = self.fail[current state]
            if char in self.transitions[current state]:
                next state = self.transitions[current state][char]
                if DEBUG:
                    print(f"Переход по '{char}' из {current_state} в
{next state}")
                current state = next state
            else:
                if DEBUG:
                    print(f"Heт перехода по '{char}' из
{current state}, переходим в корень (0)")
                current state = 0
            temp state = current state
            visited = set()
            while temp state != -1 and temp state not in visited:
                visited.add(temp state)
                if self.output[temp state]:
                    for pattern_index in self.output[temp state]:
                        pos = i - len(self.patterns[pattern index]) +
2
                        if DEBUG:
                            print(f"Найдено вхождение шаблона
{pattern index + 1} на позиции {pos}")
                        results.append((pos, pattern index + 1))
                temp state = self.output link[temp state]
        return sorted(results)
    def get vertex count(self):
        return self.state count
    def find overlapping patterns(self, text, results):
        if not results:
            return set()
        occurrences = [(pos, pos + len(self.patterns[pattern num - 1])
- 1, pattern num)
                       for pos, pattern num in results]
        overlap patterns = set()
        for i in range(len(occurrences)):
            start1, end1, pattern1 = occurrences[i]
            for j in range(len(occurrences)):
                if i != j:
                    start2, end2, pattern2 = occurrences[j]
                    if start1 <= end2 and start2 <= end1:</pre>
                        overlap patterns.add(pattern1)
                        overlap patterns.add(pattern2)
        return overlap patterns
```

```
def find pattern with wildcards (T, P, wildcard):
    substrings = [s for s in P.split(wildcard) if s]
    if not substrings:
        return [], 0, set()
    k = len(substrings)
    start positions = []
   pos = 0
    for i, sub in enumerate(P.split(wildcard)):
        if sub:
            start positions.append(pos)
        pos += len(sub) + (1 if i < len(P.split(wildcard)) - 1 else 0)</pre>
    ac = AhoCorasick(substrings)
   matches = ac.search(T)
   n = len(T)
   C = [0] * n
    for pos, pattern idx in matches:
        start pos in P = start positions[pattern idx - 1]
        text start = pos - start pos in P - 1
        if text start >= 0:
            C[text start] += 1
    result = []
    for i in range(n):
        if C[i] == k and i + len(P) - 1 < n:
            valid = True
            for j in range(len(P)):
                text_pos = i + j
                if P[j] != wildcard and T[text pos] != P[j]:
                    valid = False
                    break
            if valid:
                result.append(i + 1)
    vertex count = ac.get vertex count()
    overlapping = ac.find overlapping patterns(T, matches)
    return sorted(result), vertex_count, overlapping
if name == " main ":
    T = input().strip()
   P = input().strip()
   wildcard = input().strip()
    occurrences, vertex count, overlapping =
find pattern with wildcards(T, P, wildcard)
   print(f"Количество вершин в автомате: {vertex count}")
    if occurrences:
        for pos in occurrences:
            print(pos)
    else:
        print(-1)
    if overlapping:
```

```
print("Шаблоны с пересечениями:", ", ".join(str(p) for p in sorted(overlapping)))
else:
print("Шаблоны с пересечениями отсутствуют")
```